# ΥΠΟΛΟΓΙΣΤΙΚΗ ΝΟΗΜΟΣΥΝΗ

# ΑΣΚΗΣΗ 2

Νικόλαος Σκρέτας 4493

Εμμανουήλ Γεώργιος Εμμανουηλίδης 4669

Κωσταντίνος Δεδικούσης 2962

Σκοπός της παρούσας άσκησης είναι η υλοποίηση και μελέτη του αλγορίθμου ομαδοποίησης k-means σε σύνολο δισδιάστατων δεδομένων (ΣΔΟ). Ο αλγόριθμος εφαρμόστηκε για διαφορετικές τιμές του αριθμού ομάδων Μ, με στόχο την παρατήρηση της συμπεριφοράς του σφάλματος ομαδοποίησης καθώς και της ποιότητας των παραγόμενων clusters.
Για κάθε τιμή του Μ, ο αλγόριθμος εκτελέστηκε πολλαπλές φορές με διαφορετικές τυχαίες αρχικοποιήσεις και επιλέχθηκε η λύση με το μικρότερο σφάλμα.

## Τι Κάνει ο αλγόριθμός k-means :

Ο αλγόριθμος k-means είναι ένας επαναληπτικός αλγόριθμος ομαδοποίησης, ο οποίος χωρίζει ένα σύνολο δεδομένων σε Μ ομάδες. Αρχικά επιλέγονται Μ κέντρα ομάδων, τα οποία στη συνέχεια βελτιώνονται επαναληπτικά.
Σε κάθε επανάληψη, κάθε σημείο ανατίθεται στο κοντινότερο κέντρο βάσει της Ευκλείδειας απόστασης. Έπειτα, κάθε κέντρο ενημερώνεται ως ο μέσος όρος των σημείων που του έχουν ανατεθεί. Η διαδικασία επαναλαμβάνεται μέχρι να μην αλλάζουν πλέον οι αναθέσεις των σημείων.
Το σφάλμα ομαδοποίησης ορίζεται ως:

$$E = \sum_{i=1}^{N} \|x_i - \mu_{k(i)}\|^2$$

όπου xi είναι το i-οστό σημείο και μk(i) το κέντρο της ομάδας στην οποία ανήκει.

## Υλοποίηση Άσκηση:

Η υλοποίηση του k-means πραγματοποιήθηκε σε γλώσσα C, σύμφωνα με τις απαιτήσεις της εκφώνησης. Ο αριθμός των ομάδων Μ ορίζεται μέσω της εντολής

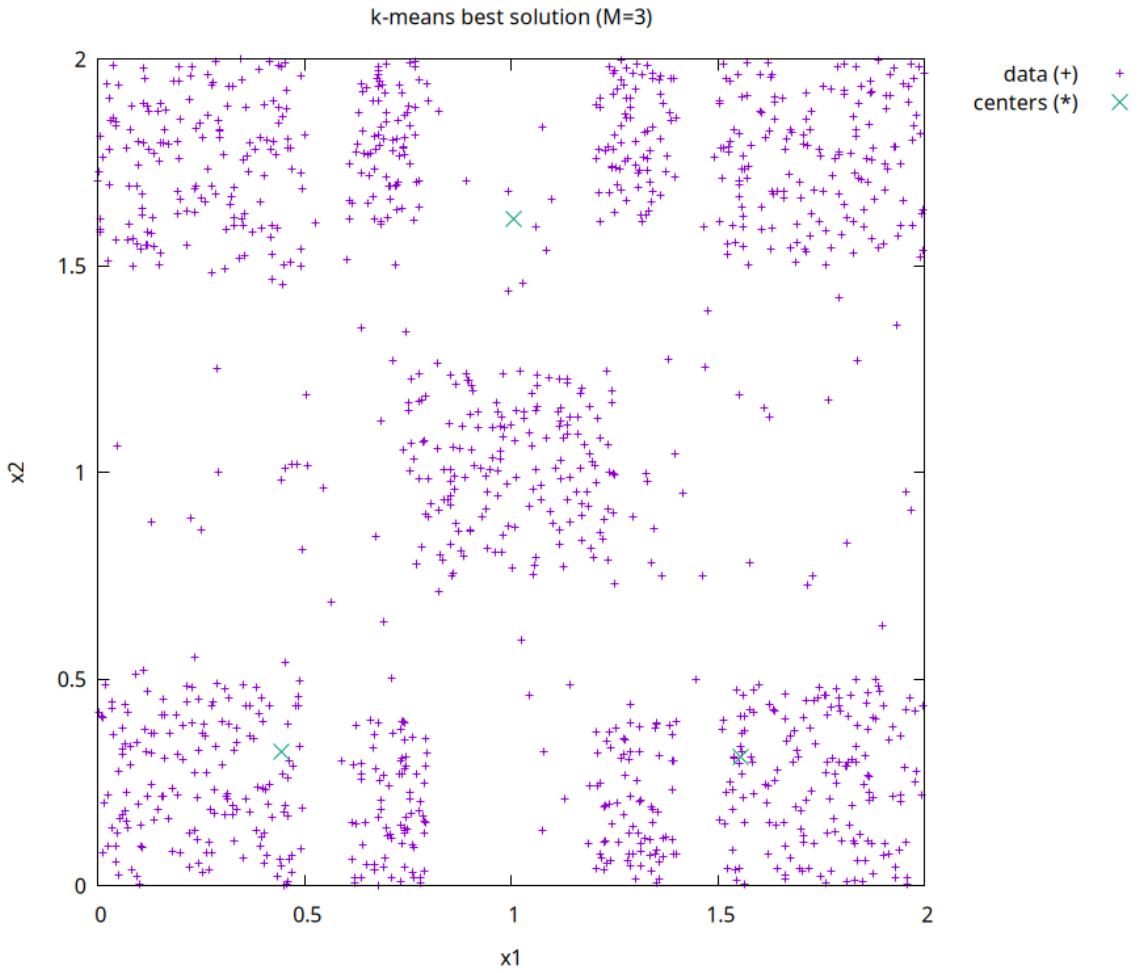
`#define`, ενώ για κάθε τιμή του M ο αλγόριθμος εκτελείται 50 φορές με διαφορετικές τυχαίες αρχικοποιήσεις.
Τα αρχικά κέντρα επιλέγονται τυχαία από τα δεδομένα. Σε κάθε εκτέλεση, ο αλγόριθμος τερματίζει όταν δεν αλλάζει καμία ανάθεση σημείου σε ομάδα. Για λόγους ασφάλειας χρησιμοποιείται μέγιστος αριθμός επαναλήψεων (MAX ITERS).
Για κάθε εκτέλεση υπολογίζεται το σφάλμα ομαδοποίησης και επιλέγεται η λύση με το μικρότερο σφάλμα, της οποίας τα κέντρα αποθηκεύονται σε αρχείο με όνομα best_M(αριθμος που επιλέγουμε).txt και centers_M(αριθμος που επιλέγουμε).txt.

## Αποτελέσματα :

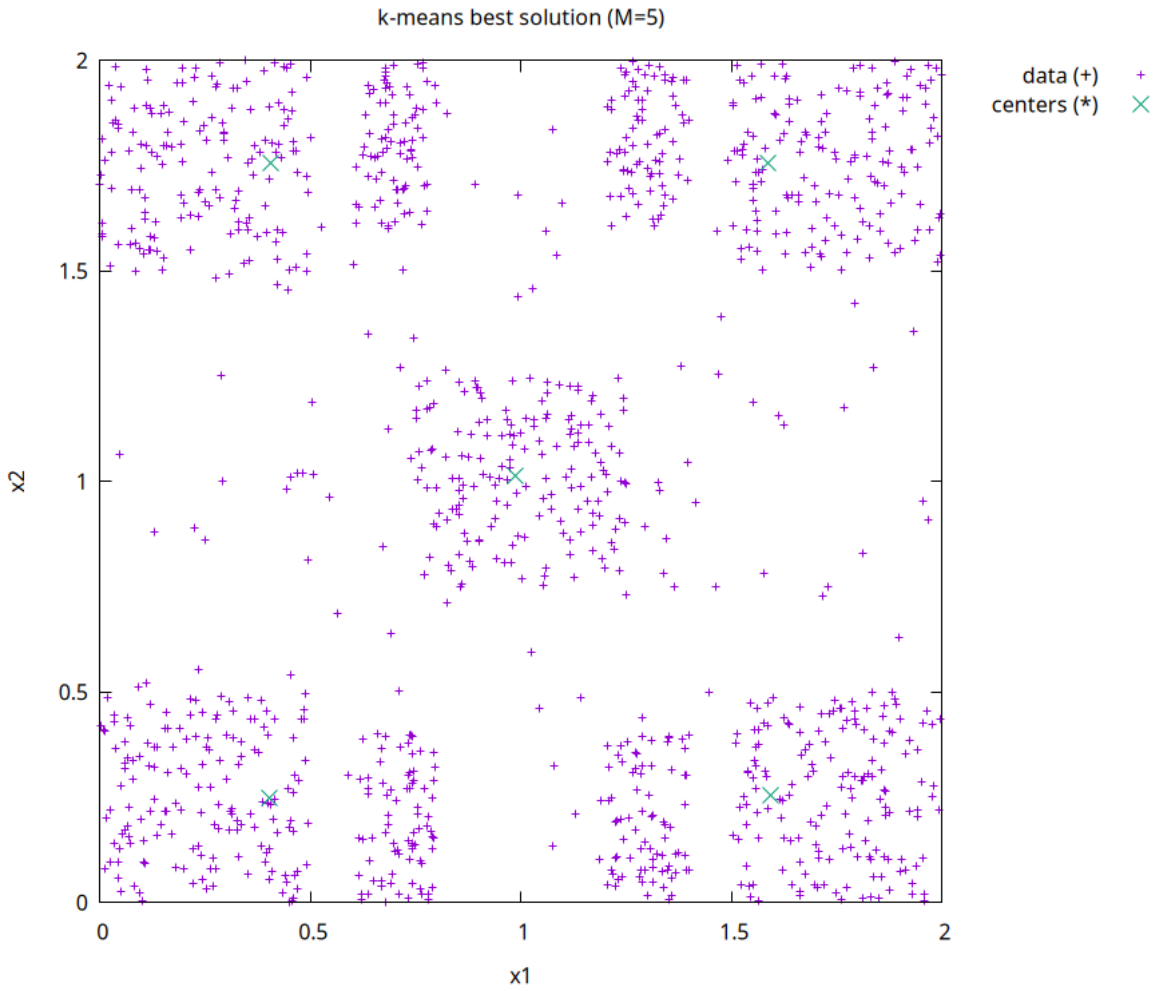
Για κάθε τιμή του $M$ (3, 5, 7, 9, 11, 13) σχεδιάστηκαν στο ίδιο σχήμα τόσο τα δεδομένα (με σύμβολο '+') όσο και τα κέντρα των ομάδων που προέκυψαν από τη βέλτιστη λύση (με σύμβολο 'X').
Για μικρές τιμές του $M$ παρατηρείται συγχώνευση φυσικών ομάδων, ενώ για μεγαλύτερες τιμές του $M$ παρατηρείται διάσπαση ορισμένων ομάδων σε περισσότερα του ενός κέντρα. Για την τιμή $M=9$, τα κέντρα τοποθετούνται στο κέντρο των φυσικών clusters των δεδομένων, γεγονός που υποδεικνύει καλή προσαρμογή του αλγορίθμου στη δομή του ΣΔΟ.

Σχήματα Ανάλογα το M:

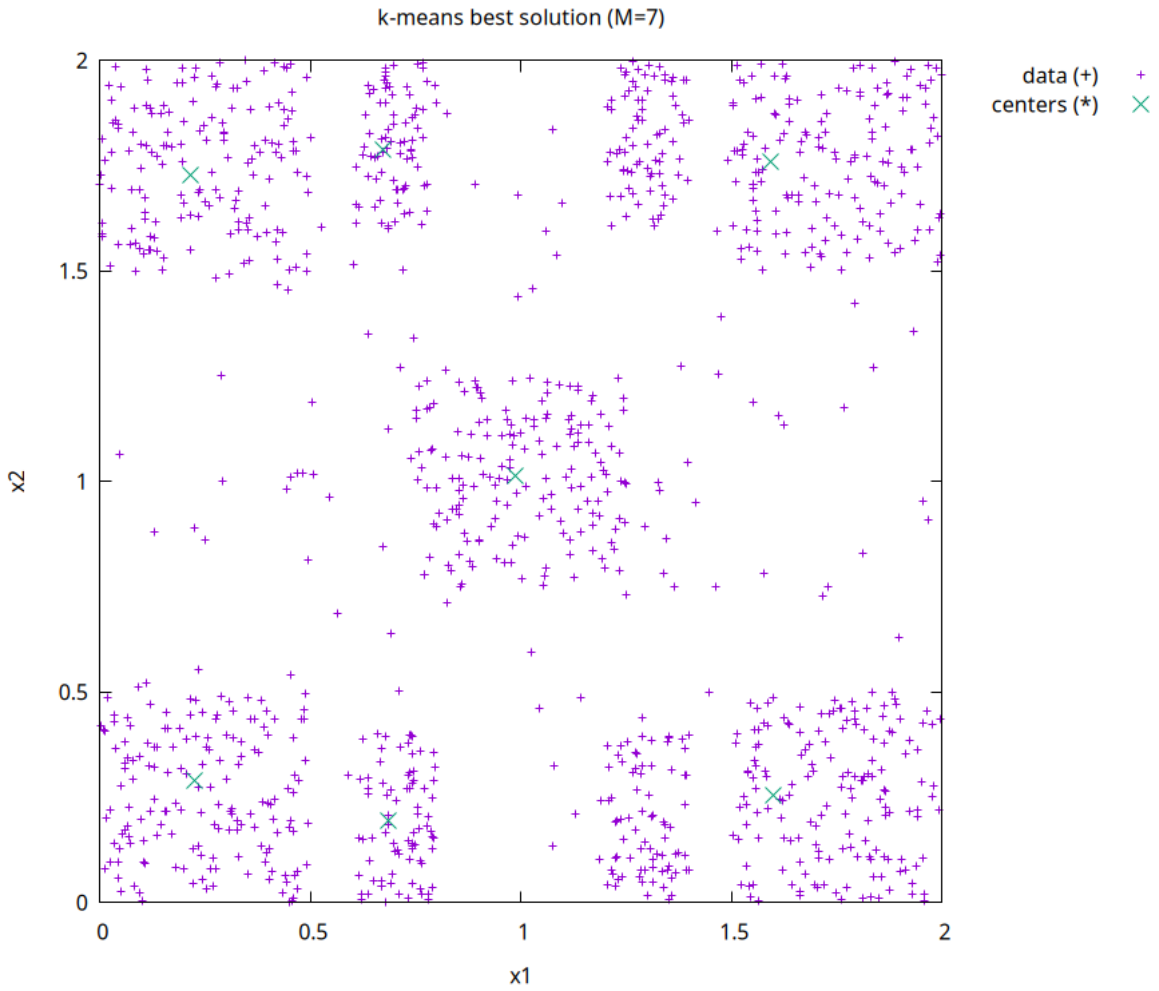
M=3



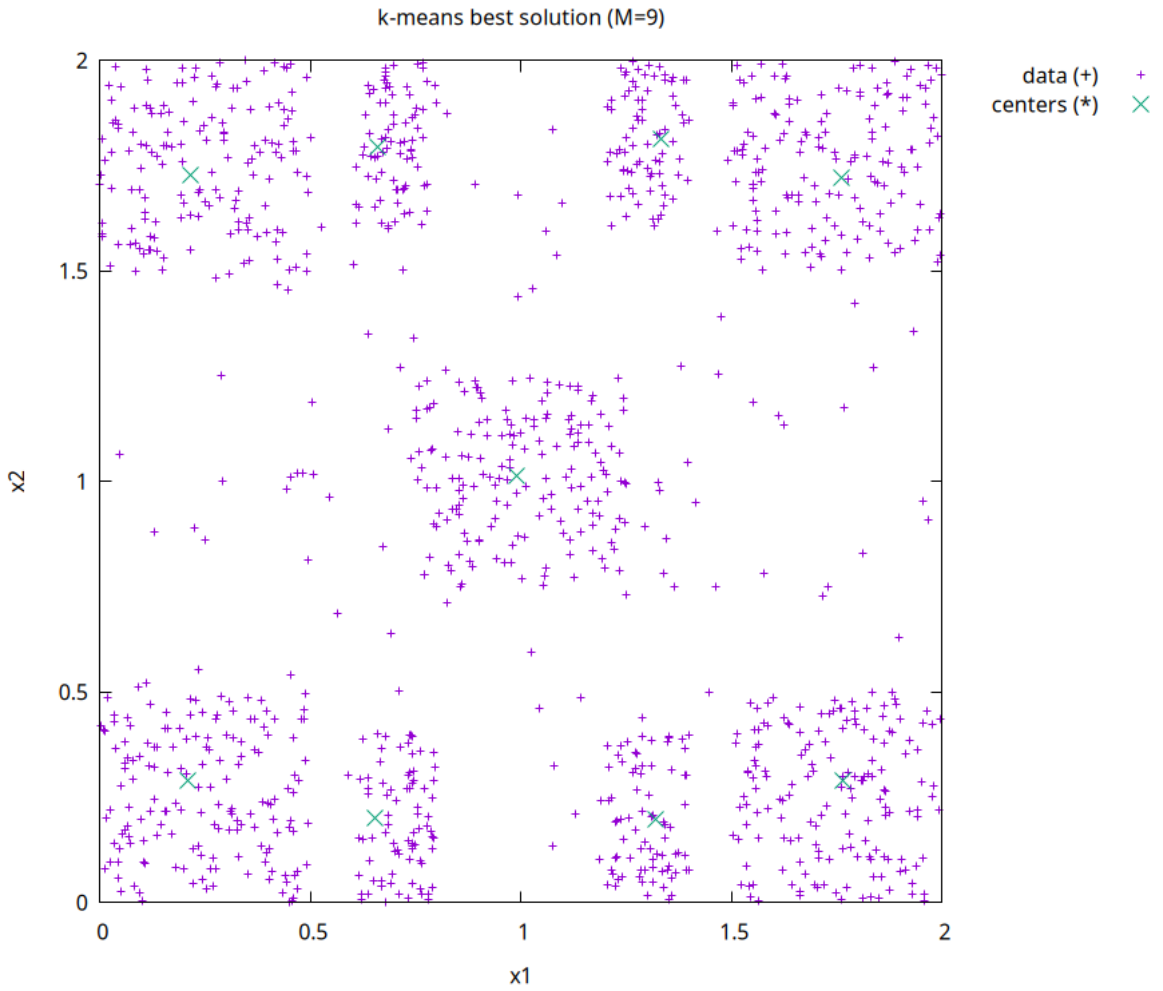

M=5



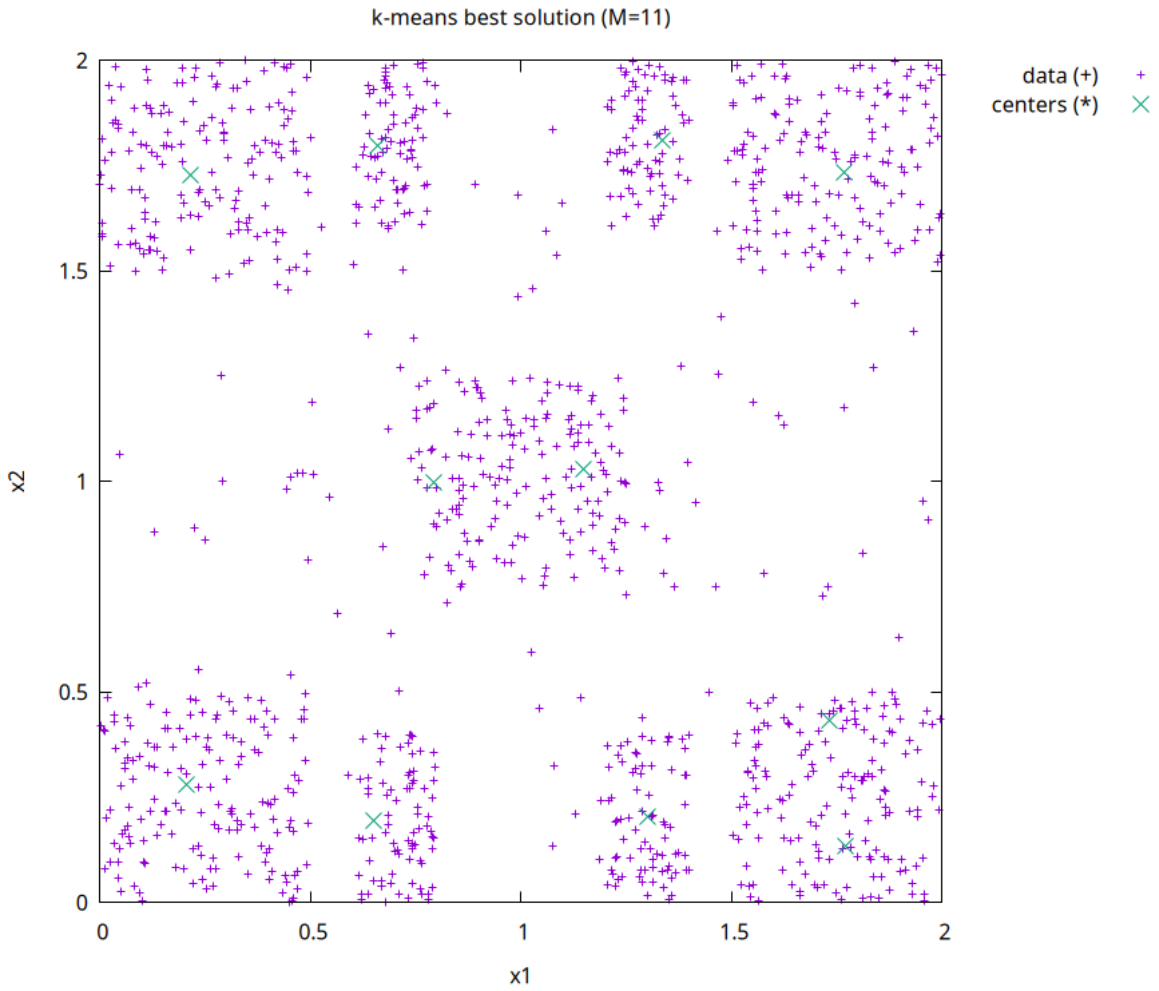

M=7



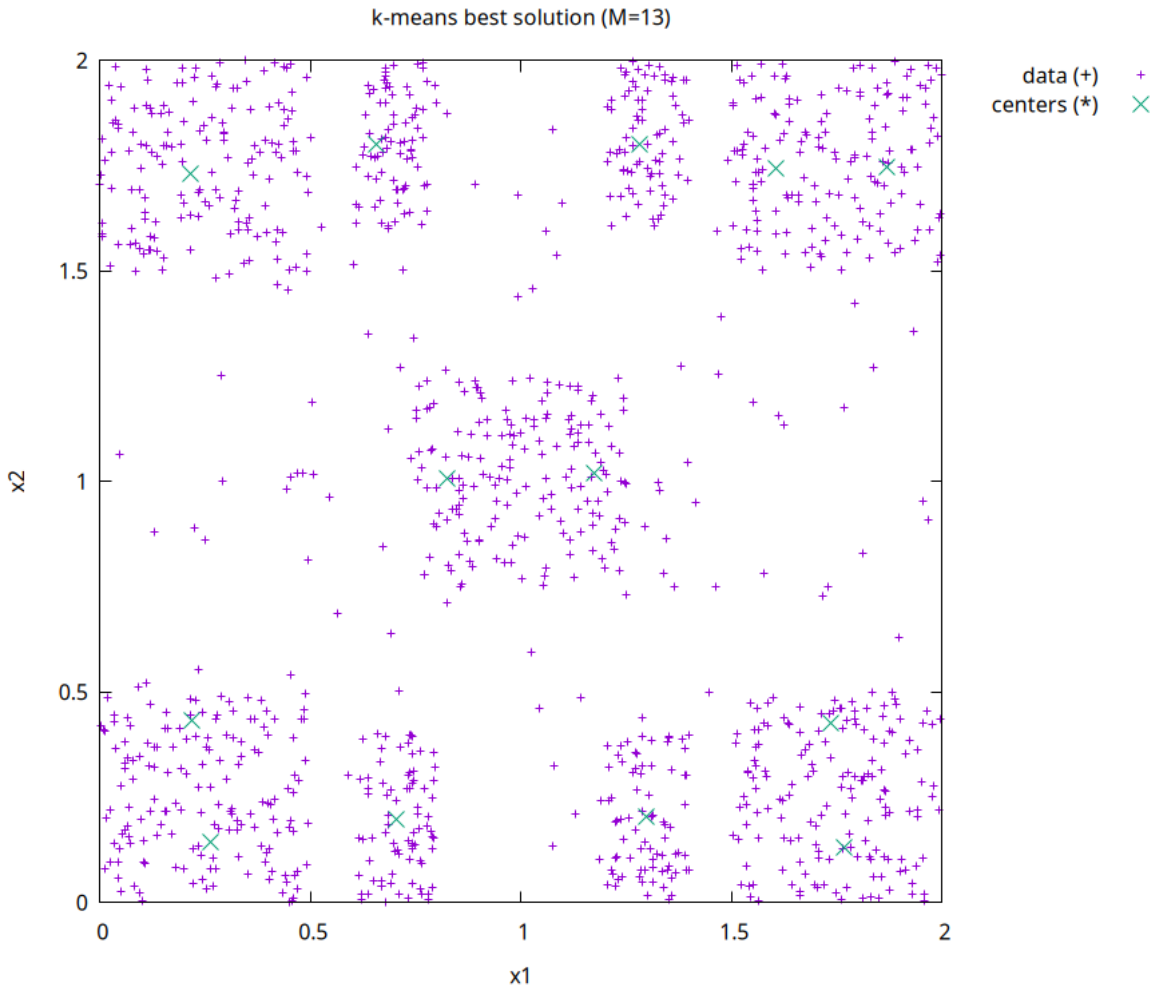

M=9




M=11

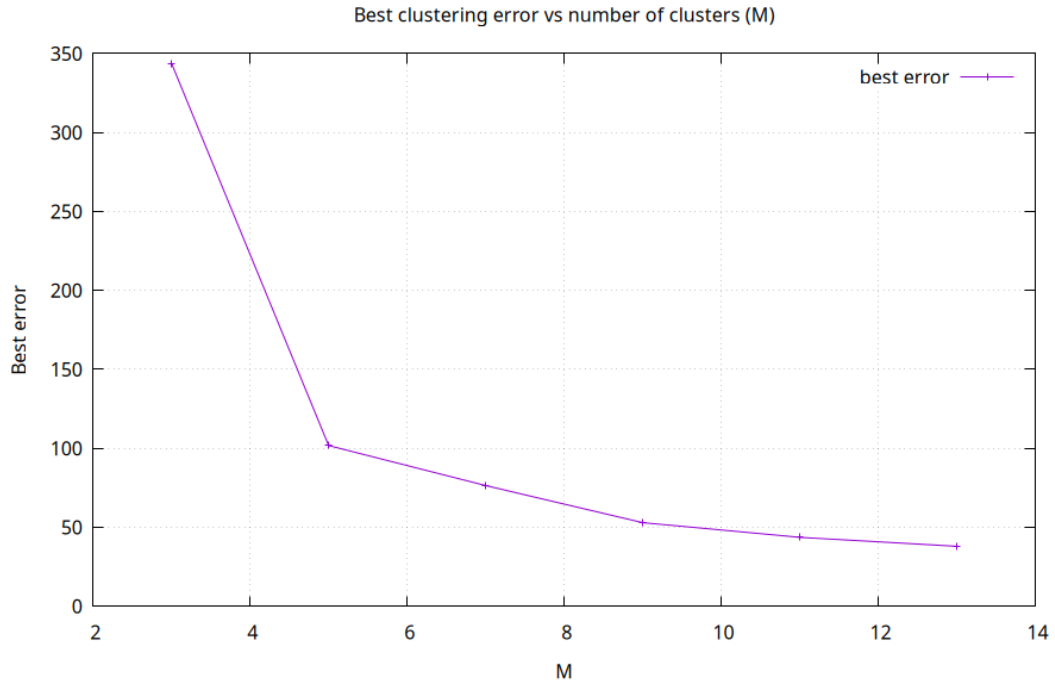



M=13




## Σφάλμα ομαδοποίησης και εκτίμηση αριθμού ομάδων:

Στη συνέχεια κατασκευάστηκε διάγραμμα που απεικονίζει τη μεταβολή του σφάλματος ομαδοποίησης ως συνάρτηση του αριθμού ομάδων M, χρησιμοποιώντας την ελάχιστη τιμή σφάλματος από τις 50 εκτελέσεις για κάθε $M$.
Παρατηρείται ότι το σφάλμα μειώνεται σημαντικά καθώς αυξάνεται το $M$ μέχρι την τιμή $M=9$, ενώ για μεγαλύτερες τιμές η περαιτέρω μείωση είναι σχετικά μικρή. Η συμπεριφορά αυτή υποδεικνύει την ύπαρξη σημείου καμπής (elbow), το οποίο μπορεί να χρησιμοποιηθεί για την εκτίμηση του πραγματικού αριθμού ομάδων.
Στο συγκεκριμένο σύνολο δεδομένων, το σημείο αυτό εντοπίζεται στο $M=9$, που συμπίπτει με τον πραγματικό αριθμό ομάδων του ΣΔΟ.




## Συμπεράσματα:

Από τα παραπάνω αποτελέσματα προκύπτει ότι ο αλγόριθμος k-means μπορεί να χρησιμοποιηθεί αποτελεσματικά για την ομαδοποίηση δισδιάστατων δεδομένων. Επιπλέον, η ανάλυση του σφάλματος ομαδοποίησης ως συνάρτηση του αριθμού ομάδων επιτρέπει την εκτίμηση του πραγματικού αριθμού clusters, ο οποίος στο παρόν ΣΔΟ είναι ίσος με 9.